

### 3. Atividade extra

O objetivo da atividade extra, é exportar arquivos flat file, para análise de comportamento de compra, inadimplência e churn dos associados.

#### Importação de bibliotecas

```
In [14]: import os
import shutil
from pyspark.sql import SparkSession
from pyspark.sql.functions import from_unixtime, col, to_timestamp, coalesce
from pyspark.sql.types import StringType, IntegerType, LongType, DecimalType, DateType
```

#### Variáveis do projeto

```
In [15]: #Variaveis de conexao com postgres
v_caminho_jar_postgres='/home/jovyan/work/jars/postgresql-9.4.1207.jar'
v_url_jdbc='jdbc:postgresql://postgres/projeto'
v_user_jdbc='airflow'
v_pass_jdbc='airflow'

#Diretorio de export do arquivo de flatfile
v_diretorio_export='/home/jovyan/work/export'
```

#### Criando sessao e contexto

```
In [16]: spark = (SparkSession
                .builder
                .master('local')
                .appName('load-postgres')
                # Add postgres jar
                .config('spark.driver.extraClassPath', v_caminho_jar_postgres)
                .getOrCreate())
sc = spark.sparkContext
```

```
In [17]: #Funcao para exportar um dataframe para arquivo csv
def f_exporta_flat_file(df, arquivo_csv):
    #Gera arquivo flat
    df.coalesce(1).write.mode('overwrite').options(header='True', delimiter=';').csv(v_diretorio_export + '/flatfile/' + arquivo_csv)

    #Renomeia arquivo e move para a pasta export
    for arquivo in os.listdir(v_diretorio_export + '/flatfile/'):
        a_arquivo=arquivo.split('.')
        if(len(a_arquivo)==2 and a_arquivo[1]=='csv'):
            shutil.move(v_diretorio_export + '/flatfile/' + arquivo, v_diretorio_export + '/' + arquivo_csv)
            print('Arquivo flat gerado: ' + v_diretorio_export + '/' + arquivo_csv)
```

```
In [21]: #Carregando dados no Dataframe
df_flat_file = (
    spark.read
    .format('jdbc')
    .option('url', v_url_jdbc)
    .option('query', '''
        select
            ass.id as id_associado,
            ass.nome,
            ass.sobrenome,
            ass.idade,
            ass.email,
            case when compras_inad.data_encerramento_conta is null then 'Sim' else 'Não' end as data_encerramento_conta,
            case when coalesce(compras_inad.qtd_dias_atraso_pgto, 0)=0 then 'Não' else 'Sim' end as qtd_dias_atraso_pgto
        from associados ass
        left join compras_inad on ass.id = compras_inad.id_associado
    ''')
    .load()
```

```

        compras_inad.data_primeira_compra,
        compras_inad.data_ultima_compra,
        (compras_inad.data_ultima_compra - compras_inad.data_primeira_compra)/30::integer as dias_compra,
        compras_inad.data_encerramento_conta,
        compras_inad.dia_ult_compra,
        compras_inad.dia_ult_compra/30 as mes_ult_compra,
        trim(replace(compras_inad.vlr_total_compras::varchar(100), '.', ',')) as vlr_total_compras,
        compras_inad.qtd_compras,
        trim(replace(compras_inad.vlr_medio_compras::varchar(100), '.', ',')) as vlr_medio_compras,
        compras_inad.qtd_dias_atraso_pgto

from target.associado ass

left join (
    select
        car.id_associado,
        min(mov.data_movimento) as data_primeira_compra,
        max(mov.data_movimento) as data_ultima_compra,
        enc.data_encerramento as data_encerramento_conta,
        coalesce(enc.data_encerramento, current_date) - max(mov.data_movimento) as dias_compra,
        sum(mov.vlr_transacao) as vlr_total_compras,
        count(distinct mov.id) as qtd_compras,
        avg(mov.vlr_transacao)::decimal(10,2) as vlr_medio_compras,
        max(fat.qtd_dias_atraso_pgto) as qtd_dias_atraso_pgto

    from target.movimento mov

    inner join target.cartao car
    on mov.id_cartao=car.id

    inner join target.encerramento_conta enc
    on enc.id=car.id_conta

    inner join (
        select
            id_cartao,
            max(qtd_dias_atraso_pgto) as qtd_dias_atraso_pgto
        from target.fatura

        group by 1
    ) fat
    on fat.id_cartao=car.id

    group by car.id_associado, enc.data_encerramento
) as compras_inad
on compras_inad.id_associado=ass.id

where ass.id>0
'''
.option('user', v_user_jdbc)
.option('password', v_pass_jdbc)
.load()
)

#Gerando flat file
f_exporta_flat_file(df_flat_file, 'associado_compras_fatura_inad.csv')

```

[Stage 6:> (0 + 1) / 1]  
Arquivo flat gerado: /home/jovyan/work/export/associado\_compras\_fatura\_inad.csv

In [22]:

```

#Carregando dados no Dataframe
df_flat_file = (
    spark.read
    .format('jdbc')
    .option('url', v_url_jdbc)
    .option('query', '''
        select

```

```

        ass.id as id_associado,
        ass.nome,
        ass.sobrenome,
        ass.idade,
        ass.email,
        compras_inad.des_transacao,
        trim(replace(compras_inad.vlr_total_compras::varchar(100), '.', ',')) as vlr_total_
        compras_inad.qtd_compras,
        trim(replace(compras_inad.vlr_medio_compras::varchar(100), '.', ',')) as vlr_medio_

from target.associado ass

left join (
    select
        car.id_associado,
        mov.des_transacao,
        sum(mov.vlr_transacao) as vlr_total_compras,
        count(distinct mov.id) as qtd_compras,
        avg(mov.vlr_transacao)::decimal(10,2) as vlr_medio_compras
    from target.movimento mov

    inner join target.cartao car
    on mov.id_cartao=car.id

    group by 1, 2
) as compras_inad
on compras_inad.id_associado=ass.id

where ass.id>0
''' )
.option('user', v_user_jdbc)
.option('password', v_pass_jdbc)
.load()
)

#Gerando flat file
f_exporta_flat_file(df_flat_file, 'associado_comportamento_compras.csv')

```

[Stage 7:> (0 + 1) / 1]  
Arquivo flat gerado: /home/jovyan/work/export/associado\_comportamento\_compras.csv

In [ ]: